

ClassARNnc : Classification et évaluation des familles d'ARN non-codants basées sur les séquences, les structures secondaires et leur combinaison à l'aide du Deep Learning

Préparé par :
Hassan Houssein Houmed

Encadrants :
Mr Raphael Mourad
Mme Christine Gaspin

June 6, 2023

Sommaire

1 Introduction

- Contexte et importance des ARN non-codants
- Présentation des différentes familles d'ARNnc étudiées

2 Méthodologie

- Présentation des données
- Architectures des modèles pour la classification binaire
- Architectures des modèles pour la classification multi-classe

3 Résultats

- Résultats de la classification de snord et trna
- Résultats de la classification de haca et u1
- Résultats de la classification de multi-classe

4 Conclusion

- Résumé des points clés

5 Perspectives

- Projet principal de ce stage
- Améliorations potentielles du modèle pour le transfert learning

6 Remerciements

Contexte et importance des ARN non-codants

- Historiquement négligés, les ARN non-codants jouent maintenant un rôle reconnu dans la régulation génétique.
- Ils sont impliqués dans diverses maladies et troubles, renforçant leur importance dans la recherche.


Présentation des différentes familles d'ARNnc étudiées

- Nous nous concentrons sur quatre familles principales : SNORD, TRNA, HACA et U1.
 - Les SNORDs participent à la maturation des ARN ribosomiques.
 - Les TRNAs servent de transporteurs d'acides aminés pendant la synthèse des protéines.
 - Les ARN HACA sont impliqués dans la formation de pseudouridine dans les ARNr et les snRNAs.
 - Les U1 sont impliqués dans l'épissage de l'ARN pré-messager.
- Chaque famille a des caractéristiques uniques et des rôles spécifiques.

Présentation des données


- Les séquences d'ARNnc sont tirées de la base de données RFAM.
- RFAM est une collection extensive d'ARN non-codants de différentes espèces, reconnue pour la rigueur de sa curation des données.
- Les structures secondaires de ces séquences ont été obtenues à l'aide de l'outil RNAFold.
- RNAFold est un logiciel qui prédit les structures secondaires d'ARN à partir de séquences, en se basant sur des calculs d'énergies libres.
- Le prétraitement des données inclut le nettoyage et le formatage approprié pour l'application du Deep Learning.

Architectures des modèles pour la classification binaire




Model architecture for RNA Sequences

Architectures des modèles pour la classification binaire




Model architecture with two inputs

Architectures des modèles pour la classification multi-classe



Model architecture for RNA Sequences

Architectures des modèles pour la classification multi-classe



Model architecture with two inputs

Résultats de la classification de snord et trna

Confusion Matrix

Model for RNA Sequences			
Actual		Predicted	
		SNORD	TRNA
	SNORD	863	0
	TRNA	3	888

Model for RNA Secondary Structures			
Actual		Predicted	
		SNORD	TRNA
	SNORD	836	27
	TRNA	72	819

Model with Two Inputs			
Actual		Predicted	
		SNORD	TRNA
	SNORD	863	0
	TRNA	3	88

Résultats de la classification de snord et trna

Metrics	Model for RNA Sequences	Model for RNA Secondary structures	Model with two inputs
Error rate	0.0017	0.0564	0.0017
Accuracy	0.9983	0.9436	0.9982
Recall	0.9966	0.9192	0.9966
Precision	1	0.9681	1
F1 score	0.9983	0.9430	0.9983
Cohen's kappa	0.9966	0.8872	0.9966
ROC AUC	0.9983	0.9439	0.9983

Table: Performance metrics for different models

Résultats de la classification de haca et u1

Confusion Matrix

Model for RNA Sequences			
Actual		Predicted	
		HACA	U1
	HACA	1582	0
	U1	2	1590

Model for RNA Secondary Structures			
Actual		Predicted	
		HACA	U1
	HACA	1517	65
	U1	112	1480

Model with Two Inputs			
Actual		Predicted	
		HACA	U1
	HACA	1582	0
	U1	0	1592

Résultats de la classification de haca et u1

Metrics	Model for RNA Sequences	Model for RNA Secondary structures	Model with two inputs
Error rate	0.0006	0.0558	0
Accuracy	0.9994	0.9442	1
Recall	0.9987	0.9296	1
Precision	1	0.9579	1
F1 score	0.9994	0.9436	1
Cohen's kappa	0.9987	0.8885	1
ROC AUC	0.9994	0.9443	1

Table: Performance metrics for different models

Résultats de la classification de multi-classe

	Precision	Recall	F1-Score	Support
SNORD	1.00	1.00	1.00	877
TRNA	1.00	0.99	1.00	877
HACA	0.99	1.00	1.00	1587
U1	1.00	1.00	1.00	1587
Accuracy: 1.00, Support: 4928				
Macro avg: 1.00, Support: 4928				
Weighted avg: 1.00, Support: 4928				
Cohen's Kappa: 0.995825				
ROC AUC: 0.998616				

	SNORD	TRNA	HACA	U1
SNORD	873	1	3	0
TRNA	1	872	3	1
HACA	1	0	1585	1
U1	1	1	2	1583

Table: Classification Report and Confusion Matrix for RNA Sequences model

Résultats de la classification de multi-classe

	Precision	Recall	F1-Score	Support
SNORD	0.78	0.88	0.83	877
TRNA	0.95	0.88	0.91	877
HACA	0.89	0.88	0.88	1587
U1	0.96	0.94	0.95	1587
Accuracy: 0.90, Support: 4928				
Macro avg: 0.89, Support: 4928				
Weighted avg: 0.90, Support: 4928				
Cohen's Kappa: 0.862524				
ROC AUC: 0.930850				

	SNORD	TRNA	HACA	U1
SNORD	772	31	65	9
TRNA	78	773	23	3
HACA	129	13	1393	52
U1	6	0	86	1495

Table: Classification Report and Confusion Matrix for RNA Secondary structures model

Résultats de la classification de multi-classe

	Precision	Recall	F1-Score	Support
SNORD	1.00	1.00	1.00	877
TRNA	1.00	1.00	1.00	877
HACA	1.00	1.00	1.00	1587
U1	1.00	1.00	1.00	1587
Accuracy: 1.00, Support: 4928				
Macro avg: 1.00, Support: 4928				
Weighted avg: 1.00, Support: 4928				
Cohen's Kappa: 0.998330				
ROC AUC: 0.999131				

	SNORD	TRNA	HACA	U1
SNORD	876	0	1	0
TRNA	1	875	1	0
HACA	1	1	1585	0
U1	0	0	1	1586

Table: Classification Report and Confusion Matrix for model with two inputs

Conclusion

- Les ARN non-codants jouent un rôle essentiel dans la régulation génétique et sont impliqués dans diverses maladies.
- Les modèles basés sur les séquences d'ARN non-codants ont montré de bonnes performances de classification.
- L'utilisation des structures secondaires peut entraîner plus d'erreurs de classification.
- Des améliorations sont nécessaires pour la prédiction des structures secondaires et l'optimisation des performances du modèle.

Perspectives

- Projet principal de ce stage : Utilisation du modèle de classification pour l'identification des séquences d'ARN mutées ou insérées dans l'évolution de virus pathogènes de la grippe aviaire chez les poulets.
- Améliorations potentielles du modèle pour le transfert learning : Possibilité d'ajuster les hyperparamètres du modèle pour améliorer ses performances, en fonction des besoins identifiés lors de l'utilisation du transfert learning.

**MERCI DE
VOTRE
ATTENTION**

